盛 开

18402852574 | shengkai866@gmail.com | 中国四川成都
出生年月：2002 年 10 月 | 汉族 | 政治面貌：群众 | 在校生
个人主页：shengkai866.github.io/personalWeb



教育背景

密歇根大学安娜堡分校（University of Michigan – Ann Arbor） 2026 年 9 月 – 2027 年 12 月
计算机科学与工程工学硕士，工程学院 安娜堡，密歇根州

密歇根大学安娜堡分校（University of Michigan – Ann Arbor） 2022 年 9 月 – 2026 年 5 月
计算机科学理学学士，文学、科学与艺术学院 GPA: 3.85 / 4.00

实习与科研经历

美团（Meituan） 2026 年 5 月 – 2026 年 8 月
软件开发工程师（实习），数据平台 中国北京

- 打通 PM 到生产的数据开发全链路：构建内部智能体覆盖知识问答、需求挖掘、指标校验与 ETL 交付，替代人工往返沟通。
- 团队知识分散在文档与 IM 对话中，易过时且互相矛盾；搭建自更新 RAG 知识库（BM25 + HNSW 混合检索、cross-encoder 重排），并用 LLM 评测流水线验证——189 题采样集（63 个知识源 × 3）检索路由准确率 100%，2,300 个片段两两矛盾扫描 0 冲突。
- 需求交接周期从约 2 天缩至约 1 天：多轮澄清把 PM 的模糊想法转化为开发工单——对照数据资产澄清指标定义，提前校验样例。
- 将越界改动从约 12% 降至约 6%：在开发方案、指标定义、代码与上线四个节点设置研发审批卡点，自动化 ETL/DDL 生成、平台测试与校验查询均需研发确认后生效，杜绝偏离 PM 签署的定义。

密歇根大学安娜堡分校（University of Michigan – Ann Arbor） 2025 年 9 月 – 至今
科研助理 – 软件工程师 · GLKB（基因组学文献知识库） glkb.org

- 在团队已建成的 3300 万篇 PubMed 文献知识图谱之上构建 GraphRAG 问答层，将 1 亿条句向量的 Faiss ANN 检索与 6.27 亿关系的 Neo4j 图遍历结合，使回答沿实体关系而非关键词展开，每条结论均可溯源到文献。
- LLM Agent 无法直接查询图数据库，易触发无边界遍历；设计 REST 工具 API ——实体检索、文献检索、关系/本体查询、子图抽取——将图操作封装为有边界的调用，并以异步 I/O 避免并发遍历阻塞。
- 将单次交互耗时从 1,596 毫秒降至 445 毫秒（提升 72%）：以 KV cache 复用跨轮上下文，Redis 缓存使重复问题跳过检索与生成。
- 计算与接口分离以应对尖峰流量：Lambda 入口完成鉴权、限流并按请求弹性扩容，转发至常驻 EC2 服务，避免模型重复加载。

项目经历

小模型 Prefill 加速大模型推理 2026 年 10 月 – 至今
跨模型 KV Cache 投影 + 选择性重算 PyTorch, Transformers, Qwen3, SLURM

- 长上下文场景下 prefill 是首 token 延迟（TTFT）的主要来源；设计混合 prefill：由 Qwen3-0.6B 读取 prompt，训练约 8600 万参数的 projector，根据其隐藏状态预测冻结的 Qwen3-8B 每一层的 residual stream，再由 8B 自身的归一化层、k/v 投影和 RoPE 计算出落在 8B 分布内的 KV Cache；只有开头和结尾少量 token 由 8B 自己计算。
- 仅靠投影的 KV 难以精确检索；引入选择性重算——根据小模型对问题的注意力选出得分最高的 10% 句子，由 8B 在原位置、同一次前向中重算——8k 长度下 RULER 从 0.64 提升至 0.85（8B 单独为 0.92）。
- 冻结大小模型、只训练 projector：先做 residual stream 对齐，再在 8B 自生成的回复上做 KL 蒸馏，梯度穿过冻结的 8B 回传；混合训练数据（问答、代码、对话、数学、检索）使文档问答 F1 从 0.19（纯网页）提升至 0.69。
- 4k–8k 下首 token 延迟加速约 2 倍，RULER 保持 8B 的约 92%，GSM8K 与 8B 持平（0.92 对 0.91）；复现 SpecPrefill（ICML 2025）作为对比，与直接丢弃未选中 token 相比，问答编造率从 13.7% 降至 5.3%。

分布式系统搜索引擎 2025 年 8 月 – 2025 年 12 月
两阶段检索 + 排序学习（Learning-to-Rank） Python, Hadoop, React, BERT

- 从零搭建端到端分布式文档搜索引擎，覆盖文本预处理、倒排索引构建、两阶段检索与排序学习（L2R），前端 React、后端 Flask REST API，解决关键词检索漏掉语义相关但无词面重合文档的问题。
- 20 万文档语料的索引构建超出单机处理能力；用 Python 与 Hadoop MapReduce 构建离线流水线，生成分片倒排索引。
- 利用 BERT 为每篇文档生成 Top-10 潜在用户查询作为索引期扩展，弥合文档表述与用户检索方式的差异，提升语义召回。
- 在 13,555 条标注样本上训练 LambdaMART 排序模型，融合 TF-IDF、BM25、Bi-/Cross-encoder 相关性及 PageRank/HITS 图特征，对 BM25 + Bi-encoder 召回的 Top-100 精排——NDCG@10 ≈ 0.51、MAP@10 ≈ 0.36，显著优于 TF-IDF/BM25 基线。

技能清单

编程语言： Python, SQL, JavaScript, C++, R, HTML/CSS
AI / 机器学习： LangChain, LangGraph, BERT/Transformers, PyTorch, scikit-learn, Pandas, NumPy
框架与云平台： Flask, FastAPI, React, Spark, Hadoop；AWS（Lambda, EC2, Amplify）
数据库： Neo4j, PostgreSQL, MySQL, MongoDB, Hive, Oracle